Kanshigan: detecção e rastreamento de robôs em vídeo de partidas de Sumô de Robôs autônomos

Eduardo Barreto, Pedro Henrique de Azeredo Coutinho Cruz, Luan Ramos de Mello e Rodrigo Mangoni Nicola

Instituto de Tecnologia e Liderança (Inteli), São Paulo, SP, Brasil

Abstract. *Autonomous 3 kg Robot Sumo matches are still analyzed by eye. The domain embodies a general tracking problem: visually similar targets in fast, non-linear motion, filmed by uncalibrated cameras without markers. We ask which detector and tracker pairs best balance accuracy and practical viability. Kanshigan, an open tracking-by-detection pipeline, uses YOLO detectors fine-tuned on SAM 3 annotations of Brazilian handheld and Japanese overhead tournament video. On one hand-reviewed round per source, YOLOv8s and YOLO26n exceed 0.96 mAP@0.5, within seed variation; domain fine-tuning, not architecture, drives accuracy. On one identity-annotated round, all eight pairs keep identity with at most one switch, while appearance-based trackers cut pipeline speed by more than half for no gain. With a motion-only tracker, the pipeline runs in real time on 1080p video on a laptop GPU and at 40 frames per second on CPU alone.*

Resumo. *Partidas de Sumô de Robôs autônomos de 3 kg ainda são analisadas a olho. O domínio concentra um problema geral de rastreamento: alvos visualmente semelhantes, em movimento rápido e não linear, filmados por câmeras não calibradas e sem marcadores. Perguntamos quais pares de detector e rastreador equilibram melhor acurácia e viabilidade prática. O Kanshigan, uma pipeline aberta de rastreamento por detecção, usa detectores YOLO ajustados com anotações do SAM 3 em vídeo de torneios brasileiros (câmera de mão) e japoneses (câmera cenital). Em um round de referência por fonte, revisado à mão, o YOLOv8s e o YOLO26n passam de 0,96 de mAP@0,5, dentro da variação entre sementes; o ajuste fino no domínio, não a arquitetura, decide a acurácia. Em um round com identidades, os oito pares mantêm a identidade com no máximo uma troca, e os rastreadores com aparência reduzem a velocidade a menos da metade sem ganho. Com um rastreador só de movimento, a pipeline roda em tempo real sobre vídeo 1080p numa GPU de notebook e a 40 quadros por segundo só na CPU.*

1. Introdução

O Sumô de Robôs é uma competição em que dois robôs disputam, sobre uma arena circular chamada *dohyo*, quem empurra o oponente para fora. A modalidade nasceu no Japão em 1989, com o torneio que se tornou o All Japan Robot-Sumo Tournament, reconhecido

como a competição de Sumô de Robôs mais longeva do mundo (Guinness World Records, 2026). Na categoria principal, robôs autônomos de até 3 kg lutam sobre um *dohyo* de 154 cm de diâmetro, sem intervenção humana durante o *round* (Fujisoft Incorporated, 2024). No Brasil, a RoboCore Experience é o maior evento de combate de robôs da América Latina (RoboCore, 2026), e torneios como a IRONCup reúnem as categorias de Sumô a cada edição (Inatel e RoboCore, 2026). A modalidade também serve ao ensino de engenharia, porque reúne projeto mecânico, eletrônica e programação num problema fechado e mensurável (Carbone *et al.*, 2022).

A categoria autônoma de 3 kg cria um problema de análise particular. Os robôs aceleram ao máximo desde a largada, e a fase que decide a partida, do primeiro contato à saída do *dohyo*, dura cerca de um segundo[1]. Contato e vitória se decidem em poucas dezenas de quadros, rápido demais para medir a olho. Ainda assim, toda a análise de desempenho depende de observação humana. As equipes ajustam estratégia e hardware pela memória e pela revisão manual de vídeo, sem medir velocidade, tempo de reação ou padrões de movimento.

O contraste com o esporte humano é grande. A visão computacional transformou a análise de futebol, basquete e tênis, com rastreamento de jogadores e bola que alimenta estatísticas, arbitragem e treino (Thomas *et al.*, 2017; Naik, Hashmi e Bokde, 2022). Essa infraestrutura, porém, supõe atletas distinguíveis, transmissões profissionais e eventos em escala de segundos. Para o Sumô de Robôs, até onde nossa busca alcança, não há pipeline, conjunto de dados nem *benchmark* publicado de análise pós-partida a partir de vídeo externo (Seção 2).

O domínio concentra um problema geral de rastreamento, e a pesquisa pergunta: *quais combinações de detector e rastreador equilibram melhor acurácia e viabilidade prática para rastrear alvos visualmente semelhantes, em movimento rápido e não linear, a partir de vídeo não calibrado e sem marcadores?* Viabilidade prática significa rodar em hardware de consumo, sem instrumentação especial. A análise só serve às equipes se rodar no computador que elas têm.

Respondemos comparando dois detectores e quatro rastreadores sobre vídeo real de torneios brasileiros e japoneses, contra um conjunto de referência revisado à mão. Nas condições medidas, a acurácia não separa as combinações, e o custo separa. Um detector YOLO com ajuste fino no recorte da arena, combinado a um rastreador só de movimento, atinge a mesma acurácia que as alternativas por uma fração do custo e roda em tempo real num notebook. O que move a acurácia é o ajuste fino no domínio, não a arquitetura.

As contribuições são: (i) seis condições que caracterizam o domínio e isolam a questão em aberto, rastrear alvos de aparência uniforme sob movimento não linear em vídeo não controlado; (ii) o Kanshigan, uma pipeline aberta de detecção, rastreamento e extração de

[1]Mediana de 1,1 s (de 0,2 a 2,2 s) em 9 rounds JP revisados à mão, com contato e saída inferidos das caixas a 10 Hz: caixas que se tocam e centro de um robô fora da elipse da arena. Os rounds inteiros duram vários segundos. Na fonte brasileira, poucos rounds tiveram contato e saída detectados, e não estimamos a mediana.

métricas para a modalidade, com a comparação de duas arquiteturas de detector e quatro rastreadores em acurácia e custo; (iii) um protocolo de anotação semiautomática com o SAM 3 (Carion *et al.*, 2025), aferido contra revisão humana em 15 rounds JP; e (iv) uma avaliação sem rótulos, ancorada no conjunto de referência, que mede onde a pipeline falha fora dele.

2. Trabalhos Relacionados

A visão computacional já aparece no Sumô de Robôs, mas embarcada no robô, não como análise externa: o robô detecta o oponente por infravermelho, ultrassom ou câmera própria durante a luta. Até onde nossa busca alcança, a análise pós-partida, feita por um observador externo a partir de vídeo de terceira pessoa, não tem pipeline, conjunto de dados nem *benchmark* publicado[2]. Organizamos a revisão em três linhas próximas do problema e delas derivamos seis condições (C1 a C6) que caracterizam o domínio (Tabela 1).

2.1. Rastreamento multiobjeto e esportes

O paradigma dominante em rastreamento multiobjeto é o rastreamento por detecção. O SORT (Bewley *et al.*, 2016) fixou a formulação mínima: um filtro de Kalman de velocidade constante prediz cada alvo no quadro seguinte, e uma atribuição por sobreposição (IoU) liga as detecções, sem usar aparência. O ByteTrack (Zhang *et al.*, 2022) passou a associar também as detecções de baixa confiança, o que reduz buracos de trajetória sob oclusão e borrão (HOTA 63,1 no MOT17). O OC-SORT (Cao *et al.*, 2023) atacou outra fragilidade: o Kalman de velocidade constante acumula erro quando o alvo manobra ou some. O método recalcula o filtro a partir das observações em torno da oclusão e atinge HOTA 63,2 no MOT17. Robôs que colidem, giram e ricocheteiam quebram justamente a hipótese de velocidade constante. Daí a primeira condição, **C1, movimento não linear**: colisões e mudanças bruscas de direção ocorrem em todo round.

Os benchmarks do MOT17 filmam pedestres de roupas distintas, que a aparência ajuda a separar. O DanceTrack (Sun *et al.*, 2022) isola o caso contrário: 100 vídeos de dança em grupo, com dançarinos uniformizados e movimento diverso. Nele, os rastreadores que dominavam o MOT17 degradam: o ByteTrack cai para HOTA 47,7 e o OC-SORT fica em 55,1 (valores da tabela do DanceTrack). Sucessores que reforçam pistas geométricas, como o C-BIoU (Yang *et al.*, 2023) e o Hybrid-SORT (Yang *et al.*, 2024), chegam a 60,6 e 62,2. Dois robôs de combate são caixas escuras e parecidas, o que define **C2, aparência uniforme entre alvos**: a identidade precisa vir do movimento.

O SportsMOT (Cui *et al.*, 2023) leva o problema a 240 vídeos de basquete, vôlei e futebol, com velocidade alta e variável. O método dos autores atinge HOTA 74,1, e o basquete, de mais contato físico, é o esporte mais difícil. O Deep-EIoU (Huang *et al.*, 2024) e o Deep HM-SORT (Gran-Henriksen *et al.*, 2024) combinam caixas expandidas

[2]Busca de junho de 2026 em mecanismo de busca web e no arXiv, com quatro strings que combinam “robot sumo”, “sumo robot” e “combat robot” a termos de visão, detecção, rastreamento, métricas e arbitragem. Strings, achados e categorização estão versionados no repositório. Não cobrimos bases autenticadas como IEEE Xplore e Scopus.

com aparência para jogadores. No Sumô de Robôs a escala temporal é mais extrema: o contato que decide o round dura poucos quadros. Daí **C3, eventos decisivos de poucos quadros**: perder dez quadros num rali de vôlei custa pouco, mas no Sumô esses quadros podem conter o empurrão que decide a partida. O SoccerNet-Tracking (Cioppa *et al.*, 2022), por fim, usa a câmera principal de transmissões profissionais de futebol, em alta resolução. O vídeo de torneios de Sumô é o oposto: câmera de mão de espectador, ângulo oblíquo e iluminação de ginásio, ao lado de câmera cenital fixa no Japão. Daí **C4, vídeo de qualidade heterogênea**.

2.2. Alvos idênticos fora dos esportes

O rastreamento de alvos indistinguíveis é um campo maduro na biologia. O idtracker.ai (Romero-Ferrero *et al.*, 2019) identifica até 100 animais sem marcadores, com acerto acima de 99,9%. O TRex (Walter e Couzin, 2021) rastreia centenas de indivíduos, e o SLEAP (Pereira *et al.*, 2022) rastreia poses de vários animais. Esses sistemas, porém, aprendem a identidade a partir do próprio vídeo. Exigem gravações longas, de câmera fixa e com fundo estável, em que todos os alvos apareçam separados ao menos uma vez. O Sumô de Robôs nega essas premissas: um round dura segundos, os robôs passam boa parte dele em contato e a câmera brasileira está na mão. Não há tempo nem condição de captura para aprender a aparência de cada robô.

2.3. Combate e robôs de competição

Dois domínios chegam mais perto do Sumô de Robôs. No combate humano, Hudovernik e Skočaj (2022) pontuam lutas de jiu-jitsu a partir de vídeo de câmera fixa, com estimativa de pose para resolver o contato entre corpos. O trabalho mostra que analisar combate em vídeo gravado é viável. Esse regime define **C5, análise pós-partida**. A técnica, porém, não se aplica a chassis rígidos, que não têm pose a estimar.

Nos robôs de competição, o SSL-Vision (Zickler *et al.*, 2010), sistema oficial da RoboCup Small Size League desde 2010, localiza robôs rápidos com câmeras fixas e padrões coloridos no topo de cada robô. Rastrear robôs rápidos é tratável quando se controla a instrumentação. O Sumô de Robôs nega essa premissa: o regulamento não prevê marcadores, o acervo de vídeo não os tem e não há câmera calibrada. Daí **C6, ausência de marcadores fiduciais**, que descarta as soluções instrumentadas e exige detectar os robôs pela aparência natural.

2.4. O recorte em aberto

Nem todas as condições pesam igual. C5 descreve o regime de uso, não uma dificuldade técnica. C6 também não mede dificuldade: quase todos os trabalhos da Tabela 1 operam sem marcadores, e a condição serve para excluir as soluções instrumentadas. C3 e C4 descrevem o caso do Sumô de Robôs, não o problema geral. O que permanece em aberto, com valor transferível, é o par **C1+C2** sob vídeo não controlado (C4, C6): rastrear alvos de aparência uniforme em movimento não linear. O DanceTrack isola esse par, mas com câmera estável e alvos inteiros no quadro. A biologia o resolve com gravações longas de câmera fixa. Sob vídeo de torneio, curto e não calibrado, e julgado pela acurácia e pelo

Tabela 1: Cobertura das seis condições do domínio (● cobre, • parcial, ○ não força). C1 movimento não linear; C2 aparência uniforme; C3 eventos decisivos de poucos quadros; C4 vídeo heterogêneo; C5 análise pós-partida; C6 ausência de marcadores. Em C5 e C6, ● indica que o trabalho opera nesse regime. É um mapa de condições, não um placar de desempenho; a última linha descreve o domínio-alvo, não um resultado.

Trabalho	**Desafio técnico**			**Regime de dados e uso**		
	C1	**C2**	**C3**	**C4**	**C5**	**C6**
ByteTrack (Zhang *et al.*, 2022)	•	•	○	○	○	●
OC-SORT (Cao *et al.*, 2023)	●	•	○	○	○	●
DanceTrack (Sun *et al.*, 2022)	●	●	○	○	○	●
SportsMOT (Cui *et al.*, 2023)	•	●	○	○	○	●
SoccerNet-Tracking (Cioppa *et al.*, 2022)	•	●	•	○	•	●
idtracker.ai (Romero-Ferrero *et al.*, 2019)	•	●	○	○	●	●
Jiu-jitsu (Hudovernik e Skočaj, 2022)	●	•	•	○	●	●
SSL-Vision (Zickler *et al.*, 2010)	●	○	●	○	○	○
Sumô de Robôs (domínio-alvo)	●	●	●	●	●	●

custo de rodar em hardware de consumo, o melhor equilíbrio segue sem resposta. É esse o recorte que a pergunta deste trabalho ataca.

Hipotetizamos que a resposta vale para outras disputas rápidas entre alvos rígidos parecidos, como outras categorias de combate de robôs; a Seção 4.6 traz um primeiro indício com o Sumô de rádio-controle.

3. Materiais e Métodos

3.1. Desenho do estudo

A pesquisa é aplicada, quantitativa e experimental. Não propomos detector nem rastreador novo: comparamos componentes existentes sobre vídeo real de torneio, contra um conjunto de referência revisado por humanos. A pergunta de pesquisa se decompõe em dois fatores manipulados. O primeiro é a arquitetura do detector: o YOLOv8s (Jocher, Chaurasia e Qiu, 2023) (11,1 M de parâmetros, 28,4 GFLOPs) contra o compacto YOLO26n (Jocher *et al.*, 2026) (2,4 M, 5,2 GFLOPs), treinados com divisão, semente e protocolo idênticos. O segundo é o algoritmo de rastreamento: quatro rastreadores aplicados às mesmas detecções, de modo que a diferença medida seja do rastreador, não do detector. As variáveis dependentes são a acurácia e o custo de execução, porque a pergunta busca o equilíbrio entre os dois.

Os experimentos se organizam em seis pontos (Tabela 2). O custo de execução é medido sobre as configurações de E2 e E4.

Tabela 2: Pontos experimentais e o que cada um isola.

ID	Configuração	Pergunta
E1	SAM 3 contra o conjunto de referência	O anotador concorda com a revisão humana?
E2	YOLOv8s e YOLO26n com ajuste fino no domínio	Quanto a capacidade do detector importa?
E3	YOLOv8s com pesos COCO, sem ajuste fino	O domínio exige treino específico?
E4	Quatro rastreadores × dois detectores, detecções fixas	A aparência melhora a identidade? A que custo?
E5	YOLOv8s com e sem 14 rounds JP extras, três sementes	Mais anotação melhora o detector?
E6	Avaliação sem rótulos e ablação da arena	Onde a pipeline falha fora do conjunto de referência?

3.2. Pipeline

A pipeline segue o paradigma de rastreamento por detecção (*tracking-by-detection*): um detector localiza cada robô por uma caixa delimitadora em cada quadro, e um rastreador liga as caixas no tempo (Figura 1). A inferência roda sobre todos os quadros, na taxa nativa do vídeo, porque os eventos decisivos duram poucos quadros. Cada estágio grava uma saída inspecionável, o que permite avaliar os componentes em separado.

Arena e calibração. O *dohyo* tem geometria fixada por regulamento: disco escuro de 154 cm de diâmetro com borda branca de 5 cm (Fujisoft Incorporated, 2024). Por isso a arena é detectada por visão clássica, sem modelo treinado. Limiarizamos a luminância para isolar a borda branca, limpamos o resultado com morfologia e ajustamos elipses aos contornos. Um escore que combina tamanho, centralidade e razão de aspecto escolhe a elipse; nos quadros em que o ajuste falha, reusamos a última elipse válida. Um círculo visto em perspectiva oblíqua projeta-se como elipse, cujo eixo maior corresponde ao diâmetro real. A razão entre o diâmetro real e o eixo maior em pixels fixa a escala em

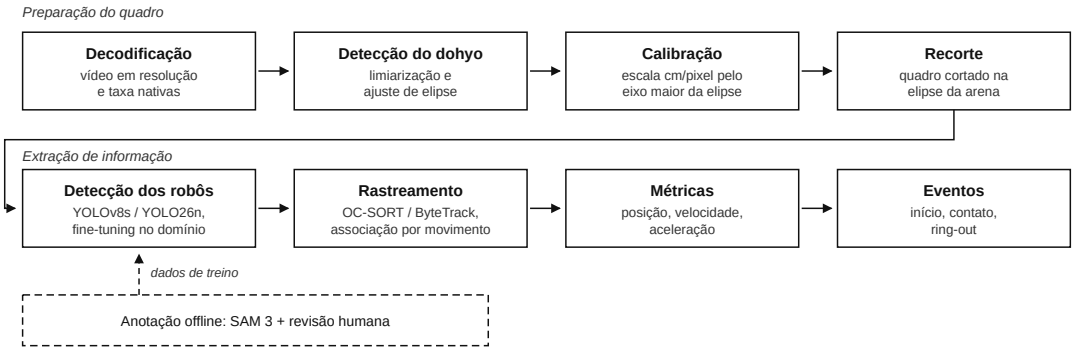


Figura 1: Estágios da pipeline. A primeira fileira prepara o quadro; a segunda extrai a informação. O ramo tracejado é a anotação offline com o SAM 3, que constrói o conjunto de treino e fica fora da inferência.

centímetros por pixel de cada quadro, sem calibração de câmera nem marcadores. A escala isotrópica ignora o escorço da perspectiva, limitação que E6 quantifica.

Recorte e detecção. Os robôs ocupam pequena fração do quadro. Reduzido à entrada de 640 px do detector, o quadro inteiro deixa os robôs com poucos pixels, que o borrão de movimento apaga, e o fundo (plateia, mãos de operadores) gera falsos positivos. Recortamos então um retângulo fixo por clipe, com margem de 20% em torno da elipse mediana de 12 quadros amostrados. No round BR de referência, o recorte descarta 62% da área do quadro e amplia os robôs em cerca de 1,2 vez na entrada do detector; as caixas voltam às coordenadas nativas por um deslocamento. O detector YOLO roda sobre o recorte. Descartamos detecções com centro fora da elipse da arena ampliada em 15% e mantemos no máximo dois robôs por quadro.

Rastreamento e identidade. Comparamos dois rastreadores de movimento e dois de aparência, implementados na biblioteca BoxMOT. O OC-SORT (Cao *et al.*, 2023) corrige o filtro de Kalman com as observações recentes, o que favorece trajetórias não lineares (C1). O ByteTrack (Zhang *et al.*, 2022) associa também as detecções de baixa confiança, comuns sob borrão. O DeepOCSORT (Maggiolino *et al.*, 2023) e o BoT-SORT (Aharon, Orfaig e Bobrovsky, 2022) somam um descritor de reidentificação por aparência (ReID), o OSNet (Zhou *et al.*, 2019) treinado em pedestres, sem ajuste ao domínio. Os dois últimos testam se a aparência acrescenta informação quando os alvos são quase idênticos (C2). Os rastreadores emitem identificadores arbitrários. Chamamos de A o robô mais à esquerda no primeiro quadro com os dois. Mantemos só as duas trajetórias mais longas, o que deixa lacunas quando uma trajetória se fragmenta.

Cinemática e eventos. A pipeline projeta cada robô no referencial do *dohyo*, em centímetros e relativo ao centro da arena. Como a arena é fixa no mundo, a posição relativa cancela a translação da câmera de mão. Um filtro de Savitzky-Golay (Savitzky e Golay, 1964) suaviza a trajetória antes de derivar velocidade e aceleração, porque diferenças finitas diretas amplificariam o ruído de detecção. Regras determinísticas marcam três eventos. O início do round é o primeiro quadro em que qualquer um dos robôs supera 15 cm/s por três quadros seguidos, ignorando os dois primeiros quadros, onde o filtro tem artefato de borda. O primeiro contato exige, no mesmo quadro, distância abaixo de 30 cm e variação de velocidade acima de 40 cm/s. A saída do *dohyo* (*ring-out*) ocorre quando o centro de um robô ultrapassa o raio da arena. Os limiares são valores iniciais fixados a priori, não calibrados. Este artigo não valida a cinemática nem os eventos; Seção 5 discute o que essa validação exige.

3.3. Dados e anotação

Não existe conjunto público do domínio. Construímos o nosso a partir de duas fontes de vídeo de torneio com regimes de câmera opostos (C4). A fonte brasileira (BR) reúne partidas da IRONCup 2025 filmadas com câmera de mão, em ângulo oblíquo, a 60 quadros por segundo. A fonte japonesa (JP) é um vídeo de 412 s de um torneio regional, gravado por câmera cenital fixa. Segmentamos os vídeos em rounds, cada um num clipe, e dividimos treino, validação e teste por round, não por quadro: quadros vizinhos são

quase idênticos, e dividir por quadro vazaria informação. O teste é, portanto, reservado por round, não por torneio. O round de teste JP sai do mesmo vídeo do treino JP, e o BR, do mesmo torneio do treino BR.

Anotar caixas à mão custaria horas por round. Usamos o SAM 3 (Carion *et al.*, 2025) como anotador semiautomático. Seguimos a prática de usar um modelo grande, de vocabulário aberto, como anotador, e um detector compacto, treinado nessas anotações, na inferência (Liu *et al.*, 2024; Ravi *et al.*, 2024). O SAM 3 propaga máscaras em vídeo a partir de um conceito textual; usamos o conceito “toy”, escolhido num teste inicial com dez conceitos. Convertemos cada máscara em caixa pela maior componente conexa e escalamos as caixas para a resolução nativa. O anotador recebe o recorte da arena reduzido a 960 px de largura e a 10 quadros por segundo. Para caber em 8 GB de memória de GPU, processa janelas de 60 quadros e reinicia o *prompt* em cada uma. Os robôs JP, pequenos e pretos em vista cenital, recebiam escore baixo para o conceito e ficavam abaixo do limiar padrão. Baixar o limiar para 0,15 e descartar caixas fora da arena recuperou os dois robôs. Os rótulos de treino não foram revisados à mão; mantivemos só os quadros com os dois robôs. Os rótulos JP de treino foram gerados antes de uma correção do filtro de caixas que, em rounds anotados depois, trocava um robô por um tripé fora da arena; não medimos esse efeito no treino original.

O conjunto de referência (*gold*) tem um round por fonte, fora do treino. O SAM 3 propôs as caixas, e nós as revisamos à mão em cada quadro amostrado a 10 Hz: 59 quadros com 112 caixas no BR e 57 quadros com 82 caixas no JP. Como a revisão parte da proposta do SAM 3, a concordância medida em E1 é um limite superior. No round BR, uma referência de identidade marca qual robô é A e qual é B nos mesmos 59 quadros (118 caixas, incluindo 6 que ficam fora do recorte), o que permite avaliar o rastreamento. A Tabela 3 resume a composição.

3.4. Treino e avaliação

Cada detector parte dos pesos COCO (Lin *et al.*, 2014) da sua arquitetura e treina com a mesma divisão, entrada de 640 px, aumento de dados padrão do Ultralytics 8.4.55, lote de 16, até 100 épocas com parada antecipada após 20 épocas sem melhora na validação, e semente 42. Congelamos os detectores reportados antes da avaliação final. O recorte da arena, porém, decidimos durante o desenvolvimento, observando falhas do detector no quadro inteiro.

Tabela 3: Composição do conjunto, em quadros anotados (amostrados a 10 Hz). A coluna Rounds soma BR e JP. Treino e validação incluem só quadros com os dois robôs rotulados, para não ensinar o detector a ignorar um deles; o conjunto de referência inclui todos os quadros amostrados do round.

Subconjunto	Rounds	Quadros BR	Quadros JP	Anotação
Treino	14	423	202	SAM 3
Validação	2	59	15	SAM 3
Referência (teste)	2	59	57	SAM 3 + revisão manual

Na detecção, medimos a precisão média (mAP) com limiar de sobreposição (IoU) de 0,5 e a média entre 0,5 e 0,95, além de precisão e revocação no ponto de F1 máximo, como reporta o Ultralytics. No rastreamento, medimos o MOTA (Bernardin e Stiefelhagen, 2008), que soma falsos positivos, falsos negativos e trocas de identidade; o IDF1 (Ristani *et al.*, 2016), que mede por quanto tempo cada robô mantém a identidade certa; e o HOTA (Luiten *et al.*, 2021), que equilibra detecção e associação. No custo, medimos quadros por segundo e pico de memória de GPU em um notebook com RTX 4070 Laptop de 8 GB. Reportamos cada número por fonte e sempre medido, nunca projetado; salvo indicação, cada um vem de um arquivo em `results/`.

Hiperparâmetros, versões (PyTorch 2.12, Ultralytics 8.4.55, BoxMOT 19.0.0) e scripts ficam versionados no repositório. O protocolo de E1 a E4 foi registrado num diário de bordo antes da execução; E5 e E6 vieram depois, em resposta à banca de qualificação. O diário documenta também os desvios, as falhas e as correções.

4. Resultados

O conjunto de referência é pequeno: um round por fonte, e um único round com identidades. Por isso tratamos diferenças pequenas como ruído e dizemos, em cada caso, o que a amostra sustenta.

4.1. Validação do anotador (E1)

O SAM 3 anota o treino, então precisa concordar com o que a revisão humana aceita. Comparamos suas caixas com as do conjunto de referência por IoU ≥ 0,5 (Tabela 4). No round BR, o modo de imagem com o conceito “robot” atinge F1 de 0,96, com IoU médio de 0,91 nas caixas casadas; o modo de vídeo com o conceito “toy”, que anotou o treino BR, não foi medido nesse round. No JP, em vista cenital, o modo de imagem quase não acha os robôs pretos e pequenos (revocação de 0,16). O modo de vídeo, que propaga as máscaras no tempo, recupera os dois robôs: revocação de 0,94 e F1 de 0,91 no round de referência JP.

Os 14 rounds JP extras de E5 dão uma medida maior do modo de vídeo. Em 448 quadros e 878 caixas revisadas, ele atinge F1 de 0,75. As caixas que ele propõe quase coincidem com as humanas (IoU de 0,94), mas cerca de três em cada dez robôs ficam sem caixa, e a revisão alterou 71% dos quadros. A revisão, portanto, não foi acabamento: foi o que tornou esses rounds utilizáveis. Os rótulos do treino reportado não passaram por essa revisão, e a qualidade deles segue desconhecida.

4.2. Detecção (E2 e E3)

Os dois detectores com ajuste fino atingem mAP@0,5 acima de 0,96 nas duas fontes (Tabela 5). O YOLO26n, com um quinto dos parâmetros, fica em 0,968 contra 0,965 no BR e em 0,993 contra 0,976 no JP. Para dar escala a essas diferenças, o YOLOv8s treinado com três sementes varia 0,019 (desvio padrão) no JP (Seção 4.5). A diferença entre arquiteturas é da mesma ordem. O conjunto sustenta, portanto, equivalência prática,

Tabela 4: Concordância do SAM 3 com a revisão humana (IoU ≥ 0,5). Toda revisão partiu da proposta do SAM 3, então os valores são limites superiores. Referência BR: modo de imagem com o conceito "robot"; as demais linhas usam "toy" com limiar 0,15. O modo de vídeo anotou o treino das duas fontes. Os 14 rounds foram anotados depois de uma correção que ordena as caixas pela distância ao centro da arena, e não medem os rótulos JP originais.

Conjunto	Modo	Precisão	Revocação	F1	IoU médio
Referência BR	imagem	0,98	0,94	0,96	0,91
Referência JP	imagem	1,00	0,16	0,27	0,92
Referência JP	vídeo	0,88	0,94	0,91	0,98
14 rounds JP	vídeo	0,80	0,71	0,75	0,94

não superioridade: a capacidade extra do YOLOv8s não rende acurácia mensurável neste domínio. O YOLO26n foi treinado com uma única semente.

O ajuste fino no domínio, por outro lado, é decisivo. Avaliamos o YOLOv8s com pesos COCO (E3) aceitando qualquer classe COCO como robô: ele atinge 0,757 no BR e 0,359 no JP. Na avaliação padrão de classe única, que compara só a classe 0 do COCO (pessoa), fica em 0,026 e 0,062. O detector genérico acha parte dos robôs como algum objeto, mas falha justamente na vista cenital. O treino no domínio leva os dois casos acima de 0,96.

A precisão alta da Tabela 5 depende do limiar. Com confiança fixa de 0,25, a que alimenta o rastreador, o YOLOv8s marca 30 falsos positivos nos 57 quadros JP (precisão de 0,72). Dezessete deles caem fora da arena e são, quase todos, o robô já fora do *dohyo*, que o treino JP rotula e a referência JP não. O filtro da arena que a pipeline aplica remove essas caixas e leva a precisão a 0,86; restam 13 falsos positivos dentro da arena. No YOLO26n, o filtro leva a precisão de 0,86 a 0,98; no BR, não muda nada. A parte fora da arena vem da convenção de anotação JP, não do detector.

4.3. Rastreamento (E4)

Aplicamos os quatro rastreadores às mesmas detecções de cada detector, no round BR

Tabela 5: Detecção no round de referência de cada fonte, sobre o recorte da arena. Precisão e revocação no limiar de confiança de F1 máximo, como reporta o Ultralytics. YOLOv8s (COCO): sem ajuste fino, com qualquer classe aceita como robô.

Detector	Fonte	mAP@0,5	mAP@0,5:0,95	Precisão	Revocação
YOLOv8s	BR	0,965	0,767	0,990	0,964
YOLOv8s	JP	0,976	0,695	0,991	0,915
YOLO26n	BR	0,968	0,772	0,963	0,955
YOLO26n	JP	0,993	0,691	0,986	0,976
YOLOv8s (COCO)	BR	0,757	0,570	0,764	0,693
YOLOv8s (COCO)	JP	0,359	0,252	0,398	0,463

Tabela 6: Grade detector × rastreador no round BR com identidades (59 quadros a 10 Hz, 118 caixas). Trocas: trocas de identidade. FPS: pipeline completa sobre o recorte, em GPU, com decodificação; média de três execuções, desvio de no máximo 3,4 FPS.

Detector	**Rastreador**	**Tipo**	**MOTA**	**IDF1**	**HOTA**	**Trocas**	**FPS**
YOLOv8s	OC-SORT	movimento	0,881	0,933	0,810	1	155
YOLOv8s	ByteTrack	movimento	0,898	0,947	0,824	0	151
YOLOv8s	DeepOCSORT	aparência	0,881	0,933	0,810	1	57
YOLOv8s	BoT-SORT	aparência	0,907	0,952	0,833	0	61
YOLO26n	OC-SORT	movimento	0,881	0,933	0,796	1	128
YOLO26n	ByteTrack	movimento	0,890	0,938	0,804	1	130
YOLO26n	DeepOCSORT	aparência	0,856	0,919	0,774	1	54
YOLO26n	BoT-SORT	aparência	0,890	0,938	0,804	1	57

com identidades (Tabela 6). As métricas usam só os 59 quadros anotados[3].

As oito combinações sustentam a identidade, com no máximo uma troca em 118 caixas. As diferenças de acurácia cabem em uma ou duas caixas: o BoT-SORT sobre o YOLOv8s lidera por uma margem que um único round não separa de ruído. A diferença de custo, ao contrário, é grande e não depende do tamanho da amostra. O passo de ReID derruba a pipeline inteira de 128 a 155 para 54 a 61 FPS. Medido sem o detector, o passo de rastreamento fica de 31 a 35 vezes mais lento com ReID. Rastreadores só de movimento entregam a mesma identidade por uma fração do custo.

Por que a aparência não ajuda? Esperávamos que a resposta fosse C2: robôs parecidos demais para o ReID separar. Medimos essa premissa e ela não se sustenta neste round. Extraímos descritores de 111 recortes do round (os visíveis com lado de ao menos 12 px) e comparamos a similaridade cosseno entre recortes do mesmo robô e de robôs diferentes. Com o OSNet que os rastreadores usam, a média intra-robô é 0,85 e a inter-robô 0,54, com área sob a curva ROC (AUC) de 0,94 na separação; o vizinho mais próximo acerta a identidade em 97% dos recortes. Até um histograma de cor separa os dois robôs (AUC de 0,92). A explicação que os dados sustentam é outra: o movimento sozinho já resolve este round, e não sobra erro de identidade para a aparência corrigir. Sobre o YOLOv8s, o DeepOCSORT produz trajetórias quase idênticas às do OC-SORT (697 de 698 linhas iguais): o ReID quase nunca muda uma associação. Este round, portanto, não estressa C2, e um confronto entre robôs de fato indistinguíveis segue sem medição.

[3]Seis das 118 caixas de identidade ficam fora do recorte, porque a referência de identidade foi gerada antes de uma correção do recorte; nenhum rastreador pode acertá-las. Avaliando só as 112 caixas visíveis, o OC-SORT sobre o YOLOv8s sobe de MOTA 0,881 para 0,929 e de HOTA 0,810 para 0,853, sem alterar a ordem entre rastreadores. Nas trajetórias cruas, antes da convenção A/B, três combinações chegam a duas trocas e o IDF1 do OC-SORT sobre o YOLOv8s cai de 0,933 para 0,925; a ordem entre rastreadores não muda.

Tabela 7: Custo da pipeline completa (decodificação, arena, recorte, detecção, OC-SORT, cinemática e eventos) no round BR de referência; média e desvio de três execuções aquecidas; a linha 4K usa um round RC. Notebook com Intel Core Ultra 9 185H e RTX 4070 Laptop de 8 GB. Memória: pico medido pelo NVML, a biblioteca de monitoramento da NVIDIA, na primeira execução de um processo com um só modelo, contexto CUDA incluído.

Entrada	**Dispositivo**	**YOLOv8s**	**YOLO26n**
1080p nativo	GPU	97,0 ± 7,0 FPS	88,9 ± 2,2 FPS
1080p nativo	CPU	21,3 ± 1,7 FPS	39,6 ± 2,3 FPS
Recorte (1558 × 506)	GPU	154,5 ± 2,2 FPS	127,7 ± 1,2 FPS
4K HEVC (RC)	GPU	16,1 ± 2,6 FPS	16,5 ± 1,4 FPS
Memória de GPU	GPU	250 MiB	272 MiB
Pesos do detector	disco	22,5 MB	5,4 MB

4.4. Custo de execução

A pipeline completa, da decodificação aos eventos, roda em tempo real sobre o vídeo nativo em GPU de notebook (Tabela 7). Em 1080p a 60 FPS, ela processa 97 FPS com o YOLOv8s e 89 com o YOLO26n, diferença que as execuções individuais não separam. No recorte, o YOLOv8s é mais rápido (155 contra 128 FPS), apesar de ter quase cinco vezes mais parâmetros: na GPU, o custo dominante não é o tamanho da rede. Na CPU do mesmo notebook, sem GPU, a ordem se inverte: o YOLO26n roda a 40 FPS e o YOLOv8s a 21. A análise pós-partida segue viável na CPU, abaixo do tempo real. Em vídeo 4K com codificação HEVC (H.265), a decodificação vira o gargalo e a pipeline cai para 16 FPS. Um processo isolado ocupa de 250 a 272 MiB de memória de GPU, contexto CUDA incluído, menos de 4% dos 8 GB da placa; com ReID, até 334 MiB. Durante a anotação, registramos no diário de bordo que o SAM 3 processava cerca de 2 FPS e ocupava cerca de 7 GB, o que justifica mantê-lo fora da inferência.

4.5. Escala do treino JP (E5)

O treino JP usa 8 dos 26 rounds que a segmentação encontra no vídeo de origem. Para medir se a quantidade de anotação limita o detector, anotamos com o SAM 3 e revisamos à mão outros 14 rounds do mesmo vídeo (448 quadros). O treino JP passou de 202 para 650 quadros. Retreinamos o YOLOv8s com os mesmos hiperparâmetros e três sementes, sem mudar os conjuntos de referência (Tabela 8).

O mAP@0,5 não separa as configurações: os intervalos se sobrepõem nas duas fontes. O que muda é o tipo de erro. Na referência JP, o detector com mais dado perde menos robôs nas três sementes (de 5 a 10 para 0 a 2, em 82), inclusive robôs borrados e na borda do quadro, e ajusta melhor as caixas (mAP@0,5:0,95 de 0,703 a 0,740, contra 0,652 a 0,695). O ganho tem custo na outra fonte. Na referência BR, o mAP@0,5:0,95 cai nas três sementes, e uma delas fragmenta um robô em caixas parciais. Os quadros novos invertem a proporção do treino (423 BR para 650 JP); o desbalanceamento é a explicação provável, mas não a testamos isoladamente. Os falsos positivos dentro da arena variam mais entre sementes que entre configurações: com a semente 0, um robô se parte em duas

Tabela 8: YOLOv8s sem e com os 14 rounds JP extras, sementes 42, 0 e 1. mAP como média ± desvio. Contagens por semente, com confiança mínima de 0,25 e IoU ≥ 0,5 (112 robôs no BR, 82 no JP). Perdidos: falsos negativos. FP dentro e FP fora: falsos positivos dentro e fora da arena, antes do filtro da pipeline.

Avaliado / treino	**mAP@0,5**	**mAP@0,5:0,95**	**Perdidos**	**FP dentro**	**FP fora**
BR / original	0,968 ± 0,006	0,786 ± 0,018	4, 4, 4	1, 28, 1	0, 0, 0
BR / + 14 JP	0,957 ± 0,032	0,728 ± 0,047	3, 4, 3	1, 70, 1	0, 1, 1
JP / original	0,963 ± 0,019	0,669 ± 0,023	5, 5, 10	13, 1, 0	17, 20, 9
JP / + 14 JP	0,978 ± 0,009	0,717 ± 0,020	0, 2, 1	0, 21, 1	54, 37, 47

ou três caixas parciais nas duas configurações. Como os rounds novos também foram revisados à mão e incluem 18 quadros com um único robô, que o treino original excluía, o experimento não separa o efeito de mais dado do efeito de dado revisado. As detecções fora da arena triplicam no JP e são, nos quadros inspecionados, o robô já fora do *dohyo*, a mesma divergência de convenção da Seção 4.2. Ampliar a anotação de uma única fonte, portanto, teve custo: melhorou a fonte ampliada e piorou a outra. Mantemos como detector reportado o treinado no conjunto original.

4.6. Avaliação sem rótulos (E6)

Fora dos dois rounds de referência não há rótulo. O domínio, porém, impõe uma restrição a toda saída correta: durante o round, há exatamente dois robôs no *dohyo*. Contamos a fração de quadros que viola essa restrição, entre o início e o fim do round que a própria pipeline marca, e ancoramos o indicador no round BR, onde a acurácia é conhecida (IDF1 de 0,93 e 6,3% de violação). O indicador conta robôs; não confere se as caixas estão certas. Nos clipes avaliados, ele coincide com a avaliação qualitativa registrada antes da medição: 44% num vídeo BR de baixa resolução e 100% num trecho da grande final do All Japan Robot-Sumo Tournament 2025. Dois clipes de execuções anteriores, cujo vídeo de origem não recuperamos, ficam em 0% (round JP de câmera fixa) e 54% (outro trecho da final).

A mesma pipeline, sem retreino, rodou nos 23 rounds de Sumô de rádio-controle (RC) do acervo da equipe ThundeRatz, uma categoria fora do treino, com robôs de outro formato e vídeo de celular. A violação mediana é de 27%. Dez dos 23 rounds ficam no regime do round de referência ou melhor, três deles com janelas curtas, abaixo de 60 quadros, em que a taxa é instável; sete passam de 50%. É um indício de que o detector transfere para outra categoria em parte dos rounds, não uma medida de acurácia.

Na grande final japonesa, transmissão oficial com arena azul, placar sobreposto e colisões violentas, o modo de falha é visível (Figura 2). No movimento lento do início, o detector acha os dois robôs, e a arena de cor nova é detectada. No movimento rápido, o borrão extremo impede as duas detecções, e a segunda metade do round fica quase sem detecção. O SAM 3, sobre o recorte e com propagação temporal, ainda sustenta um dos



Figura 2: Nosso detector (esquerda, quadro nativo) e SAM 3 (direita, recorte da arena) nos mesmos instantes do primeiro round da grande final do All Japan Robot-Sumo Tournament 2025, fora da distribuição de treino; clipe distinto dos dois trechos auditados. Em cima, movimento lento: ambos acham os dois robôs. Embaixo, movimento rápido: o detector perde os dois; o SAM 3 mantém um.

robôs. O limite não é a semelhança entre robôs, que ali carregam bandeiras distintas, mas a falta de dados de treino com esse borrão.

O estágio de arena também foi medido sem rótulos. Como o *dohyo* é fixo e tem diâmetro conhecido, um ajuste correto produz escala estável ao longo do round. Comparamos o seletor por escore com o de maior contorno branco, sobre os mesmos quadros de 30 clipes, considerando empate uma diferença menor que 0,01 no coeficiente de variação da escala. Os dois empatam em 17, o escore vence em 9 e perde em 4. Quando vence, a diferença pode ser de duas ordens de grandeza: num vídeo BR de câmera de mão, o coeficiente de variação vai de 0,44 para 0,002. O escore é indiferente com um único candidato brilhante e decisivo quando o fundo oferece concorrente, como na câmera de mão. A mesma medida mostra quanto a escala oscila. O coeficiente de variação é 0,001 na câmera fixa JP, de 0,002 a 0,064 nos três vídeos BR e 0,18 de mediana nos 24 clipes RC (os 23 rounds e um clipe de demonstração), chegando a 0,38. A oscilação mistura erro de ajuste com zoom e movimento real da câmera; o erro de escorço dentro do quadro não foi medido. Sob câmera de celular, a escala em centímetros não é confiável sem retificação, e toda velocidade herda esse erro.

5. Discussão

5.1. O que os resultados respondem

A pergunta pedia a combinação de detector e rastreador que melhor equilibra acurácia e viabilidade. Nos dados medidos, a acurácia não separa as combinações, e o custo separa. Os dois detectores com ajuste fino empatam dentro da variação entre sementes; os quatro rastreadores empatam dentro de uma ou duas caixas. A escolha, então, é decidida pelo custo. Entre rastreadores, os só de movimento vencem com folga: o ReID reduz a pipeline a cerca de 40% da velocidade sem ganho mensurável. Entre detectores, o vencedor depende do hardware: em GPU os dois ficam próximos no vídeo nativo, e o YOLOv8s é mais rápido no recorte; em CPU, o YOLO26n quase dobra a velocidade.

O que de fato moveu a acurácia foi o ajuste fino no domínio, não a arquitetura: ele levou o mAP@0,5 de 0,36 para mais de 0,97 na vista cenital, enquanto multiplicar os parâmetros por quase cinco não mudou o resultado. O recorte da arena também pesou durante o desenvolvimento, ao tirar do quadro o fundo que gerava falsos positivos, mas esse ganho não é reprodutível a partir dos artefatos salvos. A lição transferível é que, para alvos rígidos numa arena conhecida, dados do domínio rendem mais que capacidade de modelo.

Dois resultados não seguem o raciocínio que a literatura sugeria. Primeiro, o OC--SORT, desenhado para movimento não linear (C1), não superou o ByteTrack neste round. Com 59 quadros a 10 Hz, a referência registra pouco das colisões em que a correção do OC-SORT faria diferença; C1 continua sem teste adequado. Segundo, o ReID não ajudou, como no DanceTrack (Sun *et al.*, 2022), mas por outro motivo: lá os alvos são parecidos; aqui são distinguíveis, e o movimento basta. A afirmação que os dados sustentam é estreita. Quando o movimento mantém a identidade, a aparência não paga seu custo. Segue em aberto se ela compensa quando os robôs são indistinguíveis e o movimento falha, como em oclusões longas.

5.2. Ameaças à validade

Amostra. A detecção é avaliada em um round por fonte, e o rastreamento em um único round BR, com 59 quadros amostrados a 10 Hz. Trocas de identidade curtas entre quadros amostrados não aparecem na métrica. Não reportamos intervalos de confiança porque quadros de um mesmo round são fortemente correlacionados; as três sementes de E5 são a única estimativa de variância, e só para o YOLOv8s. A grade de rastreamento usa a semente 42; com a semente 0, o mesmo detector marca 28 falsos positivos dentro da arena no round BR, e não medimos o efeito disso no rastreamento.

Independência entre treino e teste. A divisão é por round, não por torneio. O round BR de referência é uma semifinal da IRONCup 2025 entre dois robôs que também aparecem no treino; um deles está em todos os rounds BR de treino e validação. O round JP sai do mesmo vídeo contínuo que o treino JP. Os números medem generalização para rounds novos de eventos conhecidos. A generalização para eventos novos só aparece na avaliação sem rótulos (Seção 4.6), e ali ela falha sob borrão extremo.

Rótulos. Os rótulos de treino não foram revisados, e a revisão dos 14 rounds JP alterou 71% dos quadros. O conjunto de referência partiu da proposta do SAM 3, e a revisão humana tende a aceitar caixas plausíveis, o que favorece o anotador em E1 e pode favorecer detectores treinados nas mesmas propostas.

Resolução temporal. No clipe BR, 48% dos pares de quadros consecutivos são quase idênticos, compatível com uma gravação de 30 FPS entregue a 60. Se confirmado, a resolução temporal efetiva do BR é a metade da nominal.

Decisões de desenvolvimento. O recorte da arena foi adotado depois de observar, no round BR de referência, a precisão do detector em quadro inteiro (cerca de 0,71). Os pesos daquele detector não foram preservados.

5.3. Cinemática e eventos

A pipeline calcula posição, velocidade e eventos, mas este trabalho não os valida, por três razões. Primeiro, a escala isotrópica chega a um coeficiente de variação de 0,38 dentro de uma partida filmada com celular (Seção 4.6); velocidades em centímetros por segundo herdam esse erro até que a arena seja retificada por homografia. Segundo, as regras de evento dependem do detector: no round BR, o início do round dispara no quadro 20 com o YOLOv8s e no quadro 310 com o YOLO26n. Terceiro, não existe conjunto anotado de eventos separado do teste, e calibrar os limiares no próprio teste vazaria a avaliação. Enquanto essa validação não for feita, a saída de eventos serve como sugestão para revisão humana, não como medida.

5.4. Trabalhos futuros

O passo de maior valor é ampliar o conjunto de referência com identidade, em mais rounds e nas duas fontes, incluindo confrontos entre robôs de fato parecidos e colisões anotadas em todos os quadros. Isso testaria C1 e C2 de verdade. O Studio, aplicação de anotação do repositório, já registra identidade, eventos e limites de round. Seguem: retificar a arena por homografia e validar a escala contra medidas conhecidas; anotar eventos num conjunto de calibração separado; reequilibrar as fontes e unificar a convenção do robô já fora do *dohyo*; incluir vídeo de transmissão com borrão no treino; e comparar detectores de outra família, como o RT-DETR (Zhao *et al.*, 2024). A longo prazo, a pipeline pode sustentar uma plataforma aberta de análise de combate de robôs.

6. Conclusão

Este trabalho perguntou quais combinações de detector e rastreador equilibram melhor acurácia e viabilidade ao rastrear alvos visualmente semelhantes, em movimento rápido e não linear, em vídeo não calibrado e sem marcadores. Usamos o Sumô de Robôs autônomo de 3 kg como domínio e construímos o Kanshigan, uma pipeline aberta de rastreamento por detecção, com detectores treinados em anotações do SAM 3 e avaliados contra rounds revisados à mão.

A resposta, nas condições medidas, é um detector YOLO com ajuste fino no recorte da arena combinado a um rastreador só de movimento, como o OC-SORT ou o ByteTrack: o YOLOv8s ou o YOLO26n quando há GPU, o YOLO26n quando só há CPU. A acurácia vem do ajuste fino no domínio, não da arquitetura, e a aparência não paga seu custo quando o movimento já mantém a identidade. A pipeline roda em tempo real sobre vídeo 1080p numa GPU de notebook, com menos de 300 MiB de memória, e a 40 FPS só na CPU.

O alcance é limitado por um round de teste por fonte e um único round com identidade, ambos de eventos presentes no treino. Cinemática e eventos são produzidos, mas não validados. O código, os scripts e resultados que geram cada tabela e o diário de bordo que registra cada decisão e cada erro estão em github.com/Eduardo-Barreto/Kanshigan.

Referências

Aharon, N., Orfaig, R. e Bobrovsky, B.-Z. (2022) “BoT-SORT: Robust Associations Multi-Pedestrian Tracking”, *arXiv preprint arXiv:2206.14651* [Preprint].

Bernardin, K. e Stiefelhagen, R. (2008) “Evaluating Multiple Object Tracking Performance: The CLEAR MOT Metrics”, *EURASIP Journal on Image and Video Processing*, 2008, p. 1–10. Disponível em: https://doi.org/10.1155/2008/246309.

Bewley, A. *et al.* (2016) “Simple online and realtime tracking”, em *IEEE International Conference on Image Processing (ICIP)*, p. 3464–3468. Disponível em: https://doi.org/10.1109/ICIP.2016.7533003.

Cao, J. *et al.* (2023) “Observation-Centric SORT: Rethinking SORT for Robust Multi--Object Tracking”, em *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, p. 9686–9696. Disponível em: https://doi.org/10.1109/CVPR52729.2023.00934.

Carbone, G. *et al.* (2022) “A robot-sumo student competition at UNICAL as a learning--by-doing strategy for STEM education”, *STEM Education*, 2(3), p. 262–274. Disponível em: https://doi.org/10.3934/steme.2022016.

Carion, N. *et al.* (2025) “SAM 3: Segment Anything with Concepts”, *arXiv preprint arXiv:2511.16719* [Preprint].

Cioppa, A. *et al.* (2022) “SoccerNet-Tracking: Multiple Object Tracking Dataset and Benchmark in Soccer Videos”, em *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, p. 3491–3502. Disponível em: https://doi.org/10.1109/CVPRW56347.2022.00393.

Cui, Y. *et al.* (2023) “SportsMOT: A Large Multi-Object Tracking Dataset in Multiple Sports Scenes”, em *IEEE/CVF International Conference on Computer Vision (ICCV)*, p. 9887–9897. Disponível em: https://doi.org/10.1109/ICCV51070.2023.00910.

Fujisoft Incorporated (2024) *All Japan Robot-Sumo Tournament Official Regulation, Version 4.2 (English)*. Disponível em: https://www.fsi.co.jp/sumo/robot/en/.

Gran-Henriksen, M. *et al.* (2024) “Deep HM-SORT: Enhancing Multi-Object Tracking in Sports with Deep Features, Harmonic Mean, and Expansion IOU”, *arXiv preprint arXiv:2406.12081* [Preprint].

Guinness World Records (2026) *Longest-Running Robot Sumo Tournament*. Disponível em: https://www.guinnessworldrecords.com/world-records/523470-longest-running--robot-sumo-tournament.

Huang, H.-W. *et al.* (2024) “Iterative Scale-Up ExpansionIoU and Deep Features Association for Multi-Object Tracking in Sports”, em *IEEE/CVF Winter Conference on Applications of Computer Vision Workshops (WACVW)*, p. 163–172. Disponível em: https://doi.org/10.1109/WACVW60836.2024.00024.

Hudovernik, V. e Skočaj, D. (2022) “Video-Based Detection of Combat Positions and Automatic Scoring in Jiu-jitsu”, em *Proceedings of the 5th International ACM Workshop on Multimedia Content Analysis in Sports (MMSports)*, p. 55–63. Disponível em: https://doi.org/10.1145/3552437.3555707.

Inatel e RoboCore (2026) *IRONCup 2026*. Disponível em: https://events.robocore.net/ironcup-2026/registration_info.

Jocher, G., Chaurasia, A. e Qiu, J. (2023) *Ultralytics YOLOv8*. Disponível em: https://github.com/ultralytics/ultralytics.

Jocher, G. *et al.* (2026) “Ultralytics YOLO26: Unified Real-Time End-to-End Vision Models”, *arXiv preprint arXiv:2606.03748* [Preprint]. Disponível em: https://docs.ultralytics.com/models/yolo26/.

Lin, T.-Y. *et al.* (2014) “Microsoft COCO: Common Objects in Context”, em *European Conference on Computer Vision (ECCV)*, p. 740–755. Disponível em: https://doi.org/10.1007/978-3-319-10602-1_48.

Liu, S. *et al.* (2024) “Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection”, em *European Conference on Computer Vision (ECCV)*, p. 38–55. Disponível em: https://doi.org/10.1007/978-3-031-72970-6_3.

Luiten, J. *et al.* (2021) “HOTA: A Higher Order Metric for Evaluating Multi-object Tracking”, *International Journal of Computer Vision*, 129(2), p. 548–578. Disponível em: https://doi.org/10.1007/s11263-020-01375-2.

Maggiolino, G. *et al.* (2023) “Deep OC-SORT: Multi-Pedestrian Tracking by Adaptive Re-Identification”, em *2023 IEEE International Conference on Image Processing (ICIP)*.

Naik, B.T., Hashmi, M.F. e Bokde, N.D. (2022) “A comprehensive review of computer vision in sports: Open issues, future trends and research directions”, *Applied Sciences*, 12(9), p. 4429. Disponível em: https://doi.org/10.3390/app12094429.

Pereira, T.D. *et al.* (2022) “SLEAP: A deep learning system for multi-animal pose tracking”, *Nature Methods*, 19(4), p. 486–495. Disponível em: https://doi.org/10.1038/s41592-022-01426-1.

Ravi, N. *et al.* (2024) “SAM 2: Segment Anything in Images and Videos”, *arXiv preprint arXiv:2408.00714* [Preprint].

Ristani, E. *et al.* (2016) “Performance Measures and a Data Set for Multi-target, Multi--camera Tracking”, em *Computer Vision – ECCV 2016 Workshops*. (Lecture Notes in Computer Science), p. 17–35. Disponível em: https://doi.org/10.1007/978-3-319-48881--3_2.

RoboCore (2026) *RoboCore Experience: Largest Robot Combat Event in Latin America*. Disponível em: https://www.robocoreexperience.com/en.

Romero-Ferrero, F. *et al.* (2019) “idtracker.ai: tracking all individuals in small or large collectives of unmarked animals”, *Nature Methods*, 16(2), p. 179–182. Disponível em: https://doi.org/10.1038/s41592-018-0295-5.

Savitzky, A. e Golay, M.J.E. (1964) “Smoothing and Differentiation of Data by Simplified Least Squares Procedures”, *Analytical Chemistry*, 36(8), p. 1627–1639. Disponível em: https://doi.org/10.1021/ac60214a047.

Sun, P. *et al.* (2022) “DanceTrack: Multi-Object Tracking in Uniform Appearance and Diverse Motion”, em *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, p. 20961–20970. Disponível em: https://doi.org/10.1109/CVPR52688.2022.02032.

Thomas, G. *et al.* (2017) “Computer vision for sports: Current applications and research topics”, *Computer Vision and Image Understanding*, 159, p. 3–18. Disponível em: https://doi.org/10.1016/j.cviu.2017.04.011.

Walter, T. e Couzin, I.D. (2021) “TRex, a fast multi-animal tracking system with markerless identification, and 2D estimation of posture and visual fields”, *eLife*, 10, p. e64000. Disponível em: https://doi.org/10.7554/eLife.64000.

Yang, F. *et al.* (2023) “Hard to Track Objects with Irregular Motions and Similar Appearances? Make It Easier by Buffering the Matching Space”, em *IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, p. 4788–4797. Disponível em: https://doi.org/10.1109/WACV56688.2023.00478.

Yang, M. *et al.* (2024) “Hybrid-SORT: Weak Cues Matter for Online Multi-Object Tracking”, em *Proceedings of the AAAI Conference on Artificial Intelligence*, p. 6504–6512. Disponível em: https://doi.org/10.1609/aaai.v38i7.28471.

Zhang, Y. *et al.* (2022) “ByteTrack: Multi-Object Tracking by Associating Every Detection Box”, em *European Conference on Computer Vision (ECCV)*, p. 1–21. Disponível em: https://doi.org/10.1007/978-3-031-20047-2_1.

Zhao, Y. *et al.* (2024) “DETRs Beat YOLOs on Real-time Object Detection”, em *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.

Zhou, K. *et al.* (2019) “Omni-Scale Feature Learning for Person Re-Identification”, em *IEEE/CVF International Conference on Computer Vision (ICCV)*, p. 3701–3711. Disponível em: https://doi.org/10.1109/ICCV.2019.00380.

Zickler, S. *et al.* (2010) “SSL-Vision: The Shared Vision System for the RoboCup Small Size League”, em *RoboCup 2009: Robot Soccer World Cup XIII*. Springer, p. 425–436. Disponível em: https://doi.org/10.1007/978-3-642-11876-0_37.